

DESENVOLVIMENTO E AVALIAÇÃO DE UM SISTEMA DE RECOMENDAÇÃO
HÍBRIDO DE FILMES BASEADO EM TÉCNICAS DE CIÊNCIA DE DADOS

Thaís Cristine de Andrade Gomes - 10721642
Paulo Ricardo de Oliveira Ramos - 10721464
Lucas Iglesias dos Anjos - 10433522

Universidade Presbiteriana Mackenzie

SUMÁRIO

1.	Introdução	3
1.1.	Contexto do trabalho	3
1.2.	Motivação	3
1.3.	Justificativa	3
1.4.	Objetivo geral e objetivos específicos da pesquisa	4
1.4.1.	Objetivo geral	4
1.4.2.	Objetivos específicos	4
2.	Referencial Teórico	5
3.	Descrição da Abordagem Proposta	6
4.	Metodologia	7
4.1.	Base de dados	8
4.2.	Tratamento e preparação dos dados	8
4.3.	Análise exploratória dos dados	8
4.4.	Modelagem	9
4.4.1.	Filtragem colaborativa	9
4.4.2.	Classificação baseada em conteúdo	9
4.4.3.	Integração híbrida	10
4.5.	Interface do sistema	10
5.	Resultados	10
5.1.	Resultados da filtragem colaborativa	10
5.2.	Resultados da análise baseada em conteúdo	11
5.3.	Resultados da integração híbrida	12
5.4.	Análise crítica dos resultados	14
6.	Conclusão e Trabalhos Futuros	15
6.1.	Conclusão	15
6.2.	Limitações do projeto	15
6.3.	Trabalhos futuros	15
7.	Referências	16

1. INTRODUÇÃO

1.1. Contexto do trabalho

Com o crescimento das plataformas digitais de entretenimento, o acesso a conteúdos audiovisuais aumentou de forma significativa. Atualmente, serviços de streaming e catálogos online oferecem milhares de filmes, com diferentes gêneros, públicos e estilos. Apesar dessa grande variedade ser algo positivo, ela também traz um problema comum para os usuários: a dificuldade de escolher o que assistir diante de tantas opções disponíveis.

Nesse cenário, os sistemas de recomendação se tornaram ferramentas importantes para ajudar na personalização da experiência do usuário. Esses sistemas utilizam dados e características dos filmes para sugerir conteúdos que tenham maior chance de agradar a cada pessoa. Hoje, grande parte das plataformas digitais utilizam algum tipo de recomendação automática como estratégia para manter o engajamento do público.

Diante disso, o presente projeto propõe o desenvolvimento de um sistema de recomendação híbrido de filmes, combinando técnicas baseadas em conteúdo e filtragem colaborativa, utilizando como base o dataset The Movies Dataset, disponível na plataforma Kaggle.

1.2. Motivação

A motivação para a realização deste projeto está relacionada à importância dos sistemas de recomendação no contexto atual da tecnologia e da análise de dados. Ao longo do curso de Ciência de Dados, foram estudadas técnicas que podem ser aplicadas na construção de modelos capazes de resolver problemas reais, e este projeto representa uma oportunidade de colocar esses conhecimentos em prática.

Além disso, a escolha de um modelo híbrido permite explorar diferentes abordagens de recomendação, possibilitando uma análise mais completa e comparativa entre métodos, o que contribui para um aprendizado mais aprofundado sobre o tema. Para garantir organização e controle de versões durante o desenvolvimento, foi criado um repositório no GitHub para centralizar o código, os dados tratados e a documentação do projeto, disponível em: <https://github.com/lcsigzs/Projeto-Aplicado-III---Mack>.

1.3. Justificativa

O desenvolvimento de soluções baseadas em dados está diretamente ligado à inovação tecnológica. Nesse sentido, o projeto pode ser associado ao Objetivo de Desenvolvimento Sustentável 9, que trata de Indústria, Inovação e

Infraestrutura, pois envolve a criação de uma solução tecnológica utilizando modelagem e análise de dados.

Também é possível relacionar o projeto ao Objetivo de Desenvolvimento Sustentável 4, que aborda Educação de Qualidade. Sistemas de recomendação podem facilitar o acesso a conteúdos audiovisuais com potencial informativo, como documentários e produções históricas, contribuindo para ampliar as possibilidades de aprendizado e formação cultural por meio da tecnologia.

O dataset utilizado possui quantidade significativa de registros e informações relevantes, como títulos, gêneros e avaliações, sendo adequado para o desenvolvimento de sistemas de recomendação tanto baseados em conteúdo quanto colaborativos. Dessa forma, a base atende às necessidades do componente curricular e aos objetivos propostos neste trabalho.

1.4. Objetivo geral e objetivos específicos da pesquisa

1.4.1. Objetivo geral

- Desenvolver e avaliar um sistema de recomendação híbrido que utilize técnicas de filtragem baseada em conteúdo e filtragem colaborativa para gerar recomendações personalizadas de filmes a partir do dataset selecionado.

1.4.2. Objetivos específicos

- Analisar a estrutura do dataset a fim de compreender suas variáveis e como elas podem ser utilizadas no sistema de recomendação.
- Realizar o pré-processamento dos dados para garantir a qualidade das informações utilizadas na modelagem.
- Implementar uma abordagem de recomendação baseada em conteúdo para explorar características como gêneros e descrições dos filmes.
- Implementar uma abordagem de filtragem colaborativa para identificar padrões de similaridade entre usuários ou itens.
- Integrar as abordagens desenvolvidas para construir um modelo híbrido mais completo.
- Avaliar o desempenho do sistema para verificar a qualidade das recomendações geradas.
- Analisar os resultados obtidos para identificar possíveis limitações e oportunidades de melhoria.

2. REFERENCIAL TEÓRICO

Os sistemas de recomendação são bastante utilizados em plataformas digitais com o objetivo de sugerir itens relevantes aos usuários, considerando seus interesses, comportamentos ou até características dos próprios itens. Atualmente, esses sistemas estão presentes em diversos contextos, como serviços de streaming, comércio eletrônico e redes sociais, sendo importantes para melhorar a experiência do usuário.

De forma geral, os sistemas de recomendação podem ser classificados em diferentes abordagens, sendo as principais a filtragem colaborativa, a recomendação baseada em conteúdo e os modelos híbridos (RICCI; ROKACH; SHAPIRA, 2015). Cada uma dessas abordagens possui características próprias e pode ser mais adequada dependendo do tipo de problema e dos dados disponíveis.

A filtragem colaborativa é baseada no comportamento dos usuários, como avaliações e histórico de consumo. A partir dessas informações, o sistema consegue identificar padrões de similaridade e recomendar itens que foram bem avaliados por usuários com perfis semelhantes. Trabalhos clássicos da área, como o de Sarwar et al. (2001), mostram que essa abordagem é bastante eficiente para identificar relações entre usuários e itens, sendo muito utilizada na prática.

Já a abordagem baseada em conteúdo utiliza informações dos próprios itens, como descrição, gênero e palavras-chave. Dessa forma, é possível recomendar itens semelhantes àqueles que o usuário já demonstrou interesse. Segundo Aggarwal (2016), esse tipo de abordagem é especialmente útil quando há uma boa quantidade de informações sobre os itens, permitindo análises mais detalhadas.

Apesar das vantagens, cada abordagem possui limitações. Por exemplo, a filtragem colaborativa pode sofrer com dados esparsos, enquanto a abordagem baseada em conteúdo pode limitar a diversidade das recomendações. Por isso, surgem os sistemas híbridos, que combinam diferentes técnicas com o objetivo de melhorar os resultados. De acordo com Burke (2002), esse tipo de modelo tende a apresentar melhor desempenho justamente por integrar múltiplas abordagens.

Além disso, estudos mais recentes vêm explorando o uso de técnicas de processamento de linguagem natural para analisar conteúdos textuais, como descrições e sinopses. Isso permite extrair informações relevantes dos itens e enriquecer os dados utilizados pelos sistemas de recomendação.

No contexto deste projeto, foi adotada uma abordagem híbrida, combinando técnicas de filtragem colaborativa com análise de conteúdo dos filmes. Dessa forma, é possível considerar tanto o comportamento dos usuários quanto as características dos próprios filmes.

3. DESCRIÇÃO DA ABORDAGEM PROPOSTA

Para o desenvolvimento do sistema de recomendação, foram utilizadas diferentes abordagens com o objetivo de analisar tanto o comportamento dos usuários quanto as características dos filmes presentes na base de dados.

Inicialmente, foi realizada uma análise exploratória da base, buscando compreender melhor sua estrutura e preparar os dados para as etapas de modelagem. Em seguida, foi implementada uma abordagem de filtragem colaborativa utilizando o algoritmo K-Nearest Neighbors (KNN). Nessa etapa, foram utilizadas informações relacionadas às avaliações dos filmes para identificar similaridades entre os itens e gerar recomendações com base no comportamento dos usuários.

Além disso, também foi desenvolvida uma abordagem baseada em conteúdo, utilizando técnicas de processamento de linguagem natural. Para essa etapa, foram consideradas informações textuais dos filmes, como título, gênero, descrição e características temáticas. O sistema também utilizou um modelo de inteligência artificial para auxiliar na classificação e enriquecimento das informações presentes na base.

Após o desenvolvimento das duas abordagens, foi realizada uma integração híbrida entre os modelos. Para isso, foram combinados os resultados da filtragem colaborativa e da análise baseada em conteúdo, permitindo gerar recomendações mais completas e contextualizadas. O sistema também possibilita o ajuste dos pesos atribuídos a cada abordagem, permitindo variar a influência entre a similaridade matemática e a análise de conteúdo nas recomendações geradas.

Além da integração dos modelos, foi desenvolvida uma interface interativa utilizando FastAPI, permitindo realizar buscas por filmes, visualizar recomendações e testar diferentes combinações de pesos entre as abordagens utilizadas no sistema.

Para avaliação inicial do sistema, foram realizadas análises qualitativas das recomendações geradas, observando se os filmes sugeridos apresentavam características semelhantes em relação aos filmes utilizados como referência. Também foram analisadas as classificações atribuídas aos filmes pela abordagem baseada em conteúdo, considerando temas, gêneros e atmosfera identificados pelo modelo.

Essas análises permitiram verificar o funcionamento inicial do sistema híbrido e identificar possibilidades de melhoria e expansão para etapas futuras do projeto.

4. METODOLOGIA

Nesta etapa do projeto, buscou-se organizar de forma clara as atividades realizadas ao longo do desenvolvimento do sistema de recomendação híbrido de filmes. O processo foi estruturado em etapas, desde a preparação da base de dados até a implementação da interface do sistema, conforme apresentado no fluxograma.

A Figura 1 apresenta o fluxo das etapas realizadas no desenvolvimento do sistema de recomendação. O processo se inicia com a utilização da base de dados, seguido pelas etapas de tratamento e análise exploratória, que permitiram preparar e compreender melhor as informações utilizadas. Em seguida, foram aplicadas as técnicas de modelagem envolvendo a filtragem colaborativa, a análise baseada em conteúdo e a integração híbrida entre as abordagens. Por fim, foi desenvolvida uma interface para realização dos testes e visualização das recomendações geradas pelo sistema.




Figura 1 – Fluxo do sistema de recomendação desenvolvido no projeto

4.1. Base de dados

Para o desenvolvimento do projeto, foi utilizada uma base de dados de filmes disponibilizada na plataforma Kaggle. A base contém informações como título, gênero, avaliações, descrições e outras características relevantes para aplicação de técnicas de recomendação.

Além da base original, também foi utilizada uma versão tratada e enriquecida dos dados, contendo informações adicionais geradas durante o desenvolvimento do projeto, como classificações temáticas e atributos relacionados aos filmes.

4.2. Tratamento e preparação dos dados

A etapa de tratamento dos dados teve como objetivo organizar e adequar as informações para utilização nas etapas de modelagem.

Foram realizadas seleções de colunas relevantes, preenchimento de valores ausentes, padronização de informações textuais e ajustes necessários para garantir maior consistência da base. Também foram criados novos atributos utilizados posteriormente na recomendação híbrida e na análise baseada em conteúdo.

4.3. Análise exploratória dos dados

Após o tratamento, foi realizada uma análise exploratória dos dados utilizando a biblioteca Pandas no ambiente Jupyter Notebook, com o objetivo de compreender melhor a estrutura da base.

Nessa etapa, foram analisadas informações como quantidade de registros, tipos de dados, colunas disponíveis, distribuição das avaliações e organização dos gêneros dos filmes. Também foram utilizadas tabelas descritivas e visualizações simples para auxiliar na interpretação dos dados e apoiar as decisões relacionadas à modelagem.




Gráfico 1 – Distribuição das avaliações dos filmes presentes na base de dados

4.4. Modelagem

Na etapa de modelagem, foram utilizadas diferentes abordagens para construção do sistema de recomendação híbrido.

4.4.1. Filtragem colaborativa

A filtragem colaborativa foi implementada utilizando o algoritmo K-Nearest Neighbors (KNN), com base nas avaliações dos usuários presentes na base de dados.

Essa abordagem permitiu identificar similaridades entre filmes a partir do comportamento dos usuários, possibilitando a geração de recomendações relacionadas aos padrões de avaliação encontrados.

4.4.2. Classificação baseada em conteúdo

A abordagem baseada em conteúdo utilizou técnicas de processamento de linguagem natural para análise das características textuais dos filmes.

Nessa etapa, foram consideradas informações como título, gênero, descrição, temas e atmosfera dos filmes. Também foi utilizado um modelo de inteligência artificial para auxiliar na classificação e enriquecimento das informações utilizadas pelo sistema.

4.4.3. Integração híbrida

Após o desenvolvimento das abordagens individuais, foi realizada uma integração híbrida entre a filtragem colaborativa e a análise baseada em conteúdo.

Para isso, foram combinados os resultados obtidos pelas duas abordagens, permitindo gerar recomendações mais contextualizadas. O sistema também possibilita o ajuste dos pesos atribuídos a cada modelo, permitindo variar a influência entre similaridade matemática e análise de conteúdo durante as recomendações.

Além disso, foram aplicadas regras de similaridade entre gêneros e critérios de filtragem para reduzir recomendações pouco relacionadas ao filme utilizado como referência.

4.5. Interface do sistema

Para facilitar a utilização e os testes do sistema, foi desenvolvida uma interface interativa utilizando FastAPI.

A interface permite realizar buscas por filmes, visualizar recomendações geradas pelo sistema híbrido e ajustar os pesos das abordagens utilizadas. Também foram implementados recursos de sugestão de filmes e exibição de informações complementares relacionadas às recomendações geradas.

5. RESULTADOS

5.1. Resultados da filtragem colaborativa

A abordagem de filtragem colaborativa foi utilizada para identificar similaridades entre filmes com base nas avaliações presentes na base de dados. A partir da aplicação do algoritmo K-Nearest Neighbors (KNN), o sistema foi capaz de gerar recomendações relacionadas aos padrões de comportamento observados entre os usuários.

Durante os testes realizados, observou-se que os filmes recomendados apresentaram características semelhantes aos filmes utilizados como referência, principalmente em relação aos gêneros e estilos predominantes.

5.2. Resultados da análise baseada em conteúdo

Na abordagem baseada em conteúdo, foram utilizadas informações textuais dos filmes, como título, gênero, descrição, temas e atmosfera. O sistema também utilizou um modelo de inteligência artificial para auxiliar na classificação e enriquecimento das informações da base.

A análise realizada permitiu identificar características relevantes dos filmes e gerar classificações mais contextualizadas. Além disso, o sistema passou a apresentar informações complementares relacionadas aos temas predominantes e à atmosfera dos filmes recomendados.




Gráfico 2 – Distribuição de filmes classificados como culturais e comerciais

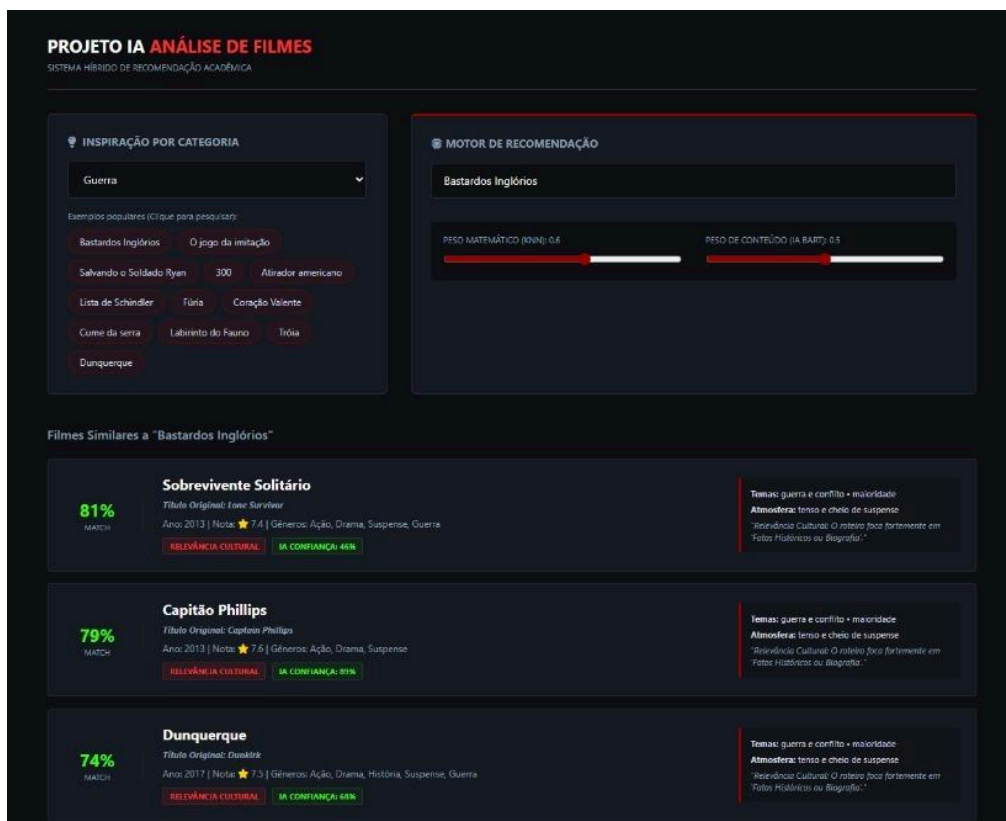


Figura 2 – Interface do sistema híbrido de recomendação de filmes

5.3. Resultados da integração híbrida

Após o desenvolvimento das abordagens individuais, foi realizada uma integração híbrida entre os modelos de filtragem colaborativa e análise baseada em conteúdo.

Com essa integração, o sistema passou a combinar informações matemáticas de similaridade com características textuais dos filmes, permitindo gerar recomendações mais completas e contextualizadas.

Além disso, foi desenvolvida uma interface interativa para realização dos testes e visualização das recomendações geradas. A interface permite realizar buscas por filmes, ajustar os pesos atribuídos às abordagens utilizadas e visualizar informações complementares relacionadas aos filmes recomendados.

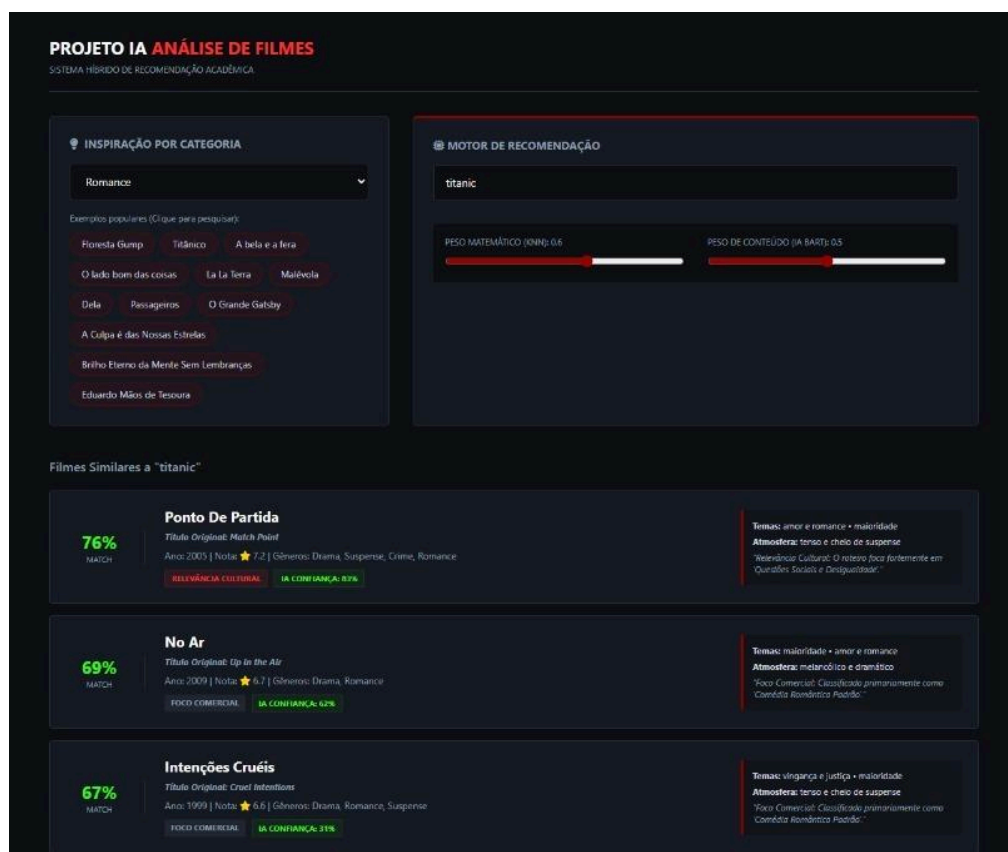


Figura 3 – Exemplo de classificação e contextualização dos filmes

Durante os testes realizados, o sistema apresentou recomendações coerentes em relação aos filmes utilizados como referência. Também foi possível observar que a alteração dos pesos influencia diretamente os resultados gerados pelo sistema híbrido.

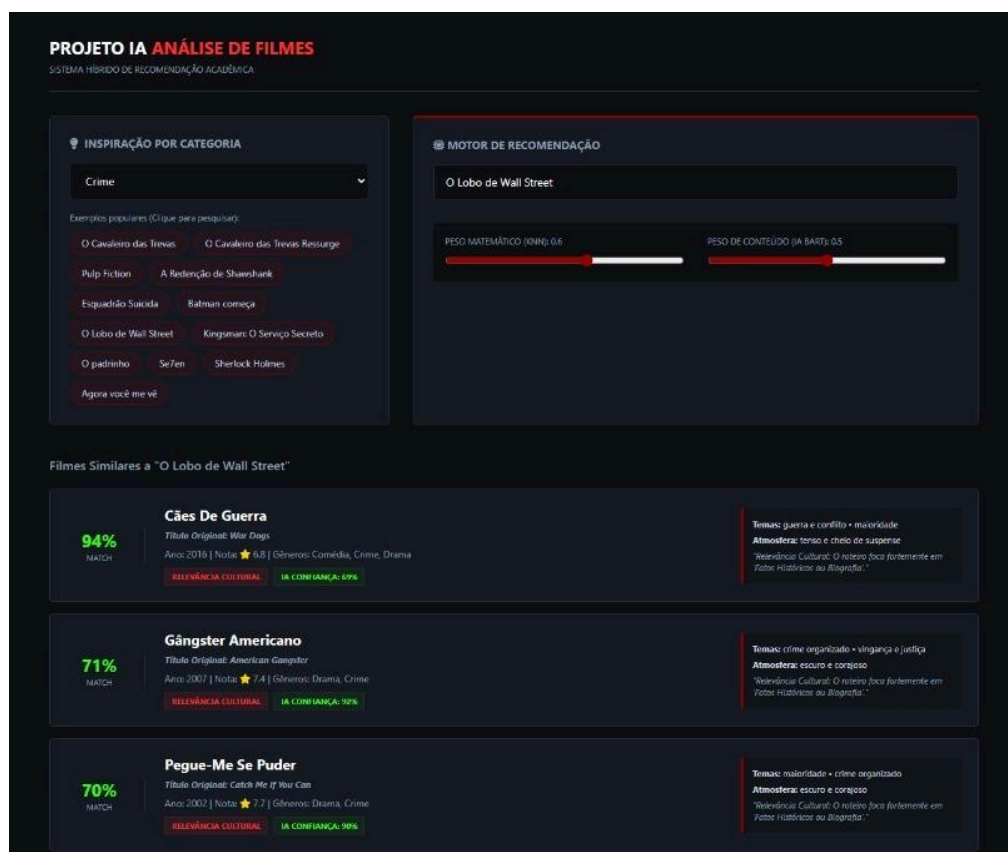


Figura 4 – Exemplo de recomendações geradas pelo sistema híbrido

5.4. Análise crítica dos resultados

Os resultados obtidos demonstraram que a utilização de uma abordagem híbrida contribuiu para tornar as recomendações mais contextualizadas, combinando informações relacionadas ao comportamento dos usuários e às características dos filmes.

Entre os pontos positivos observados, destacam-se a integração entre diferentes técnicas de recomendação, a utilização de informações textuais para enriquecimento da base e o desenvolvimento de uma interface interativa para realização dos testes.

Por outro lado, o projeto também apresentou algumas limitações, principalmente relacionadas ao tempo disponível para desenvolvimento e à ausência de métricas quantitativas mais avançadas para avaliação do desempenho do sistema.

Além disso, embora a integração híbrida tenha sido implementada, o sistema ainda possui possibilidades de refinamento e expansão, especialmente em relação à otimização dos critérios de recomendação e à ampliação dos testes realizados.

6. CONCLUSÃO E TRABALHOS FUTUROS

6.1. Conclusão

O presente projeto teve como objetivo desenvolver um sistema híbrido de recomendação de filmes utilizando técnicas de filtragem colaborativa e análise baseada em conteúdo.

Ao longo do desenvolvimento, foram realizadas etapas de preparação e análise da base de dados, implementação dos modelos de recomendação e integração das abordagens em uma interface interativa para realização de testes.

Os resultados obtidos demonstraram que o sistema foi capaz de gerar recomendações coerentes em relação aos filmes utilizados como referência, combinando informações relacionadas à similaridade matemática e às características textuais dos filmes.

Além disso, a integração híbrida permitiu tornar as recomendações mais contextualizadas, utilizando informações como gêneros, temas e atmosfera dos filmes para complementar os resultados gerados pela filtragem colaborativa.

Dessa forma, os objetivos propostos para o projeto foram alcançados de maneira satisfatória, permitindo o desenvolvimento de um protótipo funcional de sistema híbrido de recomendação.

6.2. Limitações do projeto

Apesar dos resultados obtidos, o projeto apresentou algumas limitações durante o desenvolvimento.

Entre elas, destacam-se o tempo disponível para implementação e testes mais avançados, além da ausência de métricas quantitativas mais robustas para avaliação do desempenho do sistema.

Além disso, parte das análises realizadas ocorreu de forma qualitativa, considerando principalmente a coerência das recomendações geradas em relação aos filmes utilizados como referência.

6.3. Trabalhos futuros

Como possibilidades de trabalhos futuros, o sistema pode ser expandido com a inclusão de novas métricas de avaliação, melhorias nos critérios de recomendação e ampliação da base de dados utilizada.

Também podem ser realizados testes com outros algoritmos de recomendação e modelos de inteligência artificial, buscando aumentar a precisão e a personalização das recomendações geradas.

Além disso, futuras versões do projeto podem incluir autenticação de usuários, histórico de preferências, armazenamento de avaliações e melhorias na interface do sistema.

7. REFERÊNCIAS

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. Springer, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Springer, 2016.

BURKE, R. Hybrid Recommender Systems: Survey and Experiments. 2002.

SARWAR, B. et al. Item-based Collaborative Filtering Recommendation Algorithms. WWW Conference, 2001.